SVEUČILIŠTE U ZAGREBU FAKULTET ORGANIZACIJE I INFORMATIKE V A R A Ž D I N

Dominik Posavec

Analiza statistike prodaje videoigara

SEMINARSKI RAD

SVEUČILIŠTE U ZAGREBU FAKULTET ORGANIZACIJE I INFORMATIKE V A R A Ž D I N

Dominik Posavec

Matični broj: 45046/16-R

Studij: Organizacija poslovnih sustava

Analiza statistike prodaje videoigara

SEMINARSKI RAD

Mentor/Mentorica:

Prof. dr. sc. Kornelije Rabuzin

Sažetak

Svrha ovog seminarskog rada je prikazivanje rada skladišta podataka, njihova svrha, namjena i uloga, te prikaz same analize podataka koja se odvija na temelju statistike prodaje videoigara. Kako bi što bolje precizirali svrhu ovog rada, potrebno je dakle izraditi skladište podataka, provesti određene ETL procese i prikazati postupak prijenosa tih podataka, odnosno prikaz u obliku izvještaja. Kako bi se rad mogao što kvalitetnije i efikasnije izraditi, potrebno je koristiti sljedeće alate: MySQL Workbench i PowerBI Desktop verziju od strane Microsoft-a.

Ključne riječi: skladišta podataka, ETL, alati, statistika prodaje, videoigre, PowerBI, MySQL

Sadržaj

Sadržaj	iv
1. Uvod	1
2. Osnove skladišta podataka	2
2.1. Karakteristike kreiranog skladišta podataka	2
2.2. Tehnologije korištene za rad	3
3. Izrađivanje skladišta podataka	4
3.1. Odabrani skup podataka	4
3.2. Korištenje ETL-a nad podacima	5
3.3. Model zvijezde	7
3.3.1. Dimenzijska tablica rankname	8
3.3.2. Dimenzijska tablica platform	8
3.3.3. Dimenzijska tablica publisher	9
3.3.4. Dimenzijska tablica genre	10
3.3.5. Dimenzijska tablica year	10
3.3.6. Dimenzijska tablica sales	11
3.4. UPDATE nad tablicom vgsales	11
3.5. ALTER tablice vgsales	12
3.6. Činjenična tablica fact_table	12
4. Analiza uz pomoć Power BI alata	13
4.1. Generirani izvještaji	16
5. Zaključak	19
Popis literature	20
Popis slika	21

1. Uvod

U današnje novije vrijeme tehnologije primorani smo upotrebljavati sve više i više kvalitetnija skladišta podataka, naravno uz uvjet da su ona zaštićena od neovlaštenog upada od strane zlonamjernih osoba. Isto tako s razvojem tehnologije a samim time i rastom različitih skupova podataka dolazi do potrebe da se ti podaci spremaju na određenim mjestima kako bi se mogli što učinkovitije kasnije pripremali za analizu istih. Kako bi neko poduzeće razvilo svoje sposobnosti upravljanja podacima na što kvalitetnijim metodama, potrebno je da se sama skladišta podataka informatiziraju i da budu što funkcionalnija kod njihovog rada i pristupa. Isto tako, živimo u dobu gdje se globalne promjene događaju svakodnevno i vrlo brzo, te nam je stoga izuzetno važno i pravovremeno reagirati na svaku novonastalu situaciju neovisno da je ona izazvana unutarnjim ili vanjskim čimbenicima. Osobe koje su odgovorne moraju svakodnevno donositi vrlo važne odluke koje za neke mogu rezultirati vrlo dobro, dok neke odluke mogu čak biti i katastrofalne za daljnje poslovanje. Kako bi se odluke mogle ispravno donositi potrebno je imati pristup što relevantnijim podacima, to jest, da nam informacije budu pregledne, lako razumljive i da se temelje na analizi provjerenih i integriranih podataka.

Ovaj se seminarski rad upravo bazira na izradi skladišta podataka gdje ćemo uz pomoć istog moći prikazati kvalitetno spremljene podatke u obliku izvještaja koji su netom prije kreiranja izvještaja ispravno analizirani unutar kreiranog skladišta podataka. Pomoć kod izrade praktičnog dijela seminara uveliko se odražava i na korištene tehnologije kao što su MySQL Workbench i PowerBi o kojima ćemo nešto više reći u narednim poglavljima. Spomenimo da se u radu nalazi i postupak prikupljanja podataka koji su korišteni u svrhu ovog rada, strukturiranje istih, obavljanje ETL procesa nad podacima i slično. Također, u ovome radu prikazat ćemo izradu i opis dimenzijskih i činjeničnih tablica, te prikaz istih u obliku izvještaja.

2. Osnove skladišta podataka

Prema nekim definicijama skladišta podataka možemo opisati kao temelj za dobivanje izvještaja koji su ključni za donošenje kvalitetnih poslovnih odluka. Isto tako, skladišta podataka objedinjuju podatke koji su prikupljani tokom dugi niz godina poslovanja poduzeća i koja su dospjela iz različitih izvora. Također ona nam predstavljaju i novu generaciju računarskog sustava za dodatne potpore u odlučivanju. Obuhvaćaju podatke koje su subjektivnog područja i koji su potrebni za odlučivanje u nekom određenom području s nekim ciljem, svrhom i namjenom. Samim time, skladišta sadrže i logički integrirane podatke iz raznih aplikacija dok su ti isti podaci prema nekim pravilima nepromjenjivi u smislu obrade. Kako bi se omogućilo predviđanje i uspoređivanje podataka, skladišta su također vremenski usmjerena jer sadrže podatke koji opisuju pojave karakterizirane za dulje vremensko razdoblje. [1]

Dakle, skladišta podataka predstavljaju subjektno orijentirane, integrirane, nepromjenjive i vremenski dinamične skupove podataka koji se koriste kao potpora kod odlučivanja u nekim bitnim fazama. Ono je i proces gdje podaci prikupljaju i upravljaju iz mnogih drugih izvora koji su agregirani, ekstrahirani, podrobni i obogaćeni ciljem potpore analize i donošenju procesu odluka. Po sadržaju i po nekim tehničkim zahtjevima, skladište podataka je i drugačije u odnosu na transakcijski sustav iako se transakcijski sustav ponaša kao njegova pretpostavka, no međutim, skladište podataka možemo shvatiti i kao sučelje koje dijeli operativne obrade od aplikacija za potporu u odlučivanju. [1]

2.1. Karakteristike kreiranog skladišta podataka

Izrađivanje skladišta podataka u ovome radu koriste se podaci koji su preuzeti sa stranice kaggle.com i odnose se na analiziranje statistike prodaje videoigara. Kaggle.com je web stranica koja sadrži velik i širok spektar skupova podataka iz različitih područja. Uz mogućnost korištenja skupova podataka, navedena web stranica nudi i ostale mogućnosti kao što su učenja kroz različitih lekcija, kako bi osoba mogla proširiti svoje znanje u ostalim područjima IT-a. Uz pomoć preuzetih podataka, moći ćemo dobiti uvid u karakteristike videoigara, primjerice zastupljenost poduzeća koje najviše proizvodi i prodaje videoigre, zatim kojeg su žanra, odnosno namjena, platforma za koju je videoigra namijenjena i slično.

Dataset koji je preuzeti sadrži sljedeća obilježja i podatke:

- Rank broj pod kojim se nalazi određena videoigra
- ➤ Name naziv videoigre
- Platform platforma za koju je namijenjena

- Year godina izdanja videoigre
- Genre vrsta odnosno žanr videoigre
- Publisher naziv izdavača koji je plasirao videoigru na tržište
- ➤ NA_Sales sveukupni broj NA prodaje
- EU_Sales sveukupno broj prodaju u EU
- > JP Sales sveukupni broj JP prodaje
- Other_Sales sveukupni broj ostale prodaje
- Global_Sales globalni sveukupni broj prodaje

2.2. Tehnologije korištene za rad

Za ovaj projektni zadatak korištene su sljedeće tehnologije: MySQL Workbench, PowerBI i MySQL. Izrada skladišta podataka obavlja se u alatu MySQL Workbench koji nam ujedno predstavlja i grafički prikaz dizajniranih baza podataka koji također integrira razvoj SQLa, administraciju, dizajn baze podataka, stvaranje i održavanje u jedinstveno razvojno okruženje. Alat je besplatan i dostupan svim uzrastima te je namijenjen radu na bilo kojem operacijskom sustavu. Također, omogućava smanjenje rizika, troškova i složenosti u razvoju, uvođenju i upravljaju kritičnim poslovnim MySQL aplikacijama na kojima rade administratori baze podataka. Uz prethodna obilježja također omogućuje i modeliranje, generiranje, upravljanje bazom podataka, pogodan je za sinkronizaciju i usporedbu shema. Administratorima omogućuje da izvrše reverzni inženjering postojećih baza podataka ili aplikacija kako bi arhitektima koji rade na dizajniraju baza podataka pružili bolji uvid u dizajn same baze podataka. Pomoću migracija baze podataka osigurava i korištenje čarobnjaka za vizualnu migraciju podataka kao što je migracija baza podataka koja uključuju migracije s Microsoft SQL poslužiteljem, MS Access i slično. Pruža mogućnosti korisnicima da definiraju i ciliaju na određeni izvor podataka netom prije samo procesa migracije te ostale brojne prednosti. [2]

Alat koji služi za prikazivanje izvještaja je PowerBI i on se definira kao zbirka softverskih usluga i aplikacija koji zajedno rade i kako bi naše nepovezane izvore podataka pretvorili u koherentne, interaktivne i vizualno predočene. Alat se može koristiti na računalu, pod nazivom Power BI Desktop, zatim kao internetska usluga, Power BI usluga i kao verzija na mobilnim operacijskim sustava koji je namijenjen za Android, Windows ili iOS uređaje. Potrebno je spomenuti kako alat sadrži i dva bitna elementa a to su Power BI Report Builder koji služi za stvaranje izvješća i PowerBI Report Server koji se definira kao lokalni poslužitelj izvješća na kojem možemo objavljivati vlastita izvješća. [3]

3. Izrađivanje skladišta podataka

U ovome poglavlju naglasak je na pronalaženju i prikazivanju izvora podataka koji će se dalje koristiti za rad s podacima i u konačnici prikazivanje izvještaja istih kao i djelovanje ETL (eng. Extract, Transform, Load) nad njime.

3.1. Odabrani skup podataka

Odabrani skup podataka koji je pronađen i preuzet odnosi se na prodaju videoigara i navedemo skupu podataka (eng. Dataset) možemo pristupiti na kaggle.com web adresi kao što smo to prethodno naveli u radu. Prilikom preuzimanja dataseta, podaci su pohranjeni u format naziva .csv (eng. Commaseparated values). Broj redaka koji se nalazi u datasetu je točno 16599 i svaki je redak različit u odnosu na ostale retke.

4	А	В		С		D	Е		F	G	н	1.0	J	K	L	М	N	
1	Rank, Nam	e,Platfo	rm,Y	ear,Ge	nre,P	ublish	er,NA S	ales,E	U Sale	s,JP Sal	es,Other	Sales,Glob	al Sales					
2	1,Wii Spo	rts,Wii,2	006,S	ports,	Ninte	ndo,41	.49,29.0	2,3.77	,8.46,8	2.74			_					
3	2,Super N	lario Bro	5.,NE	s,1985	,Platf	orm,N	intendo	,29.08	,3.58,6	.81,0.77,	40.24							
4	3,Mario K	art Wii,V	/ii,20	08,Rac	ing,N	intend	lo,15.85,	12.88,	3.79,3	.31,35.82								
5	4,Wii Spo	rts Resor	t,Wii	,2009,	Sports	,Ninte	ndo,15.	75,11.	01,3.2	8,2.96,33								
6	5,Pokemo	n Red/P	oken	non Blu	ie,GB	,1996,	Role-Pla	ying,N	Vinten	do,11.27	8.89,10.22	,1,31.37						
7	6,Tetris,G	B,1989,P	uzzle	,Ninte	ndo,2	3.2,2.	26,4.22,0	.58,30	0.26									
8	7,New Su	per Mari	o Bro	s.,DS,2	2006,F	latfor	m,Ninte	ndo,1	1.38,9.	23,6.5,2.	9,30.01							
9	8,Wii Play	,Wii,200	6,Mis	c,Nint	endo	,14.03,	9.2,2.93	2.85,2	29.02									
10	9,New Su	per Mari	o Bro	s. Wii,	Wii,2	009,Pla	tform,N	linten	do,14.	59,7.06,4	.7,2.26,28	62						
11	10,Duck H	unt,NES,	1984	,Shoot	er,Ni	ntend	,26.93,0	.63,0.	28,0.47	7,28.31								
2	11,Ninten	dogs,DS	2005	,Simul	ation	,Ninte	ndo,9.07	7,11,1.	93,2.7	5,24.76								
13	12,Mario	Kart DS,D	S,200	05,Rac	ng,Ni	ntend	0,9.81,7	57,4.1	3,1.92	,23.42								
14	13,Pokem	on Gold	/Poke	emon S	Silver,	GB,19	99,Role-	Playin	ng,Nint	endo,9,6	.18,7.2,0.	71,23.1						
15	14,Wii Fit	,Wii,200	7,Spo	rts,Nir	itend	0,8.94	8.03,3.6	,2.15,2	22.72									
16	15,Wii Fit	Plus,Wii	,2009	,Sport	s,Nin	tendo	9.09,8.5	9,2.53	,1.79,2	2								
17	16,Kinect	Adventu	res!,	X360,2	010,N	lisc,M	crosoft	Game	Studio	s,14.97,4	.94,0.24,1	.67,21.82						
18	17,Grand	Theft Au	to V,	PS3,20	13,Ac	tion,Ta	ke-Two	Intera	active,	7.01,9.27	,0.97,4.14	21.4						
19	18,Grand	Theft Au	to: Sa	n And	reas,l	S2,20	04,Actio	n,Take	e-Two	Interacti	ve,9.43,0.	1,0.41,10.5	7,20.81					
20	19,Super	Mario W	orld,9	SNES,1	990,P	latforr	n,Ninter	ndo,12	2.78,3.7	75,3.54,0	55,20.61							
21	20,Brain A	ge: Trair	You	r Brain	in Mi	nutes	a Day,D	5,2005	,Misc,I	Nintendo	,4.75,9.26	,4.16,2.05,	20.22					
22	21,Pokem	on Diam	ond/	Poken	non P	earl,D	5,2006,R	ole-Pl	aying,	Nintendo	,6.42,4.52	,6.04,1.37,	18.36					
23	22,Super	Mario La	nd,GE	3,1989	Platfo	orm,N	ntendo,	10.83,	2.71,4	.18,0.42,	18.14							
24	23,Super	Mario Br	os. 3,	NES,19	88,PI	atform	,Ninten	do,9.5	4,3.44	,3.84,0.4	5,17.28							
25	24,Grand	Theft Au	to V,	X360,2	013,A	ction,	Take-Tw	o Inte	ractive	,9.63,5.3	1,0.06,1.3	3,16.38						
26	25,Grand	Theft Au	to: V	ice Cit	,PS2,	2002,	ction,Ta	ke-Tv	vo Inte	eractive,	3.41,5.49,0	.47,1.78,16	.15					
27	26,Pokem	on Ruby	/Pok	emon	Sapph	ire,GE	A,2002,	Role-F	Playing	,Ninten	do,6.06,3.9	,5.38,0.5,1	5.85					
28	27,Pokem	on Black	/Pok	emon	White	,DS,20	010,Role	-Playi	ng,Nin	tendo,5	57,3.28,5.	55,0.82,15.	32					
0	28,Brain A	σe 2: Μα	re Tr	aining	in Mi	nutes	a Day D	2005	Duzzla	Ninten	do 2 44 5	26 5 22 1 1	8 15 3					

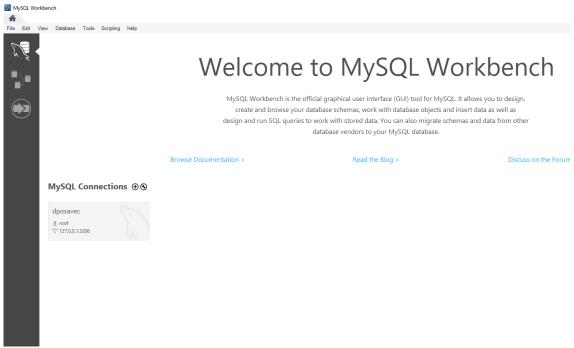
Slika 1. Prikaz dijela preuzetog skupa podataka, [autorski rad]

Na prethodnoj fotografiji moguće je vidjeti dio skupa podataka koji je preuzet i koji će se koristiti u svrhu ovog rada. Za prikaz prethodne fotografije koristio se alat MS Excel. Svaki redak, odnosno svaki zapis sadrži sljedeće atribute redom navedene: Rank, Name, Platform, Year, Genre, Publisher, NA_Sales, EU_Sales, JP_Sales, Other_Sales i Global_Sales.

3.2. Korištenje ETL-a nad podacima

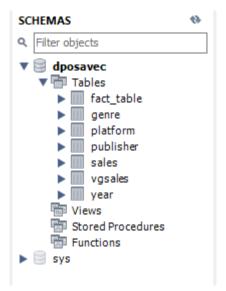
ETL možemo definirati kao postupak koji ekstrahira podatke iz različitih izvornih sustava, te iste podatke transformira i učitava ih u skladište podataka (eng. Data Warehouse). Da bi se zadržala vrijednost koje nam alat nudi za donošenje odluka, sustav skladišta podataka mora se mijenjati s poslovnim promjenama. ETL je ponavljajuća aktivnost koji se može raditi na dnevnoj, tjednoj ili mjesečnoj razini i mora biti vrlo dobro dokumentirana i automatizirana. ETL pomaže tvrtkama u analiziranju svojih poslovnih podataka za donošenje kritičnih poslovnih odluka. Transakcijske baze podataka ne mogu odgovoriti na složena poslovna pitanja koja se odnose na ETL, stoga sam ETL pruža metodu premještanja podataka iz različitih izvora u skladište podataka. Omogućuje provedbu uzoraka podataka između izvora i ciljanog sustava. Isto tako njegov postupak može izvoditi složene transformacije i zahtijeva dodatno područje koje će se koristiti za pohranu podataka. Isto tako ETL nam pomaže u migraciji podataka u skladište podataka i pomaže u poboljšavanju produktivnosti jer se kodificira i ponovo upotrebljava bez potrebe za tehničkim vještinama, te se u osnovi dijeli na tri osnovna koraka, a to su ekstrakcija, transformacija i učitavanje. [4]

Netom prije same provedbe ETL principa i metoda, potrebno je omogućiti spajanje MySQL Workbench alata sa serverom koji je u ovom primjeru nazvan "dposavec" uz pomoć kojeg je dalje potrebno izraditi sve potrebne tablice unutar iste baze.



Slika 2. Prikaz servera, [autorski rad]

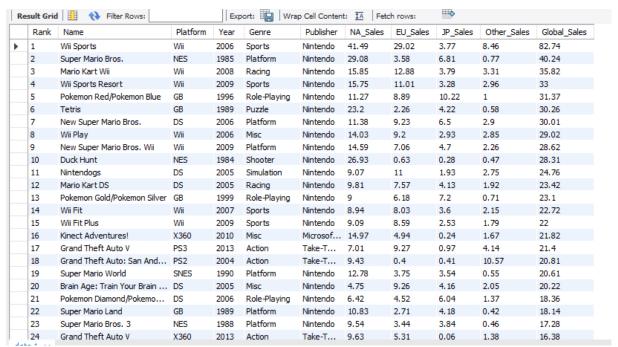
Prethodna slika prikazuje početni zaslon MySQL Workbench alata i naziv servera sa kojim radimo.



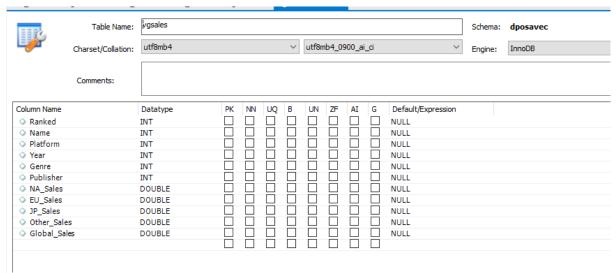
Slika 3. Popis tablica, [autorski rad]

Prethodna fotografija prikazuje popis tablica koje se nalaze u shemu i u nastavku ćemo prikazati rezultate koji se nalaze u dotičnim tablicama.

Na sljedećoj fotografiji možemo vidjeti učitani dataset, te numeričke i tekstualne vrijednosti koje se nalaze u istoj, a dok fotografija nakon nje prikazuje atribute navedenog dataseta.



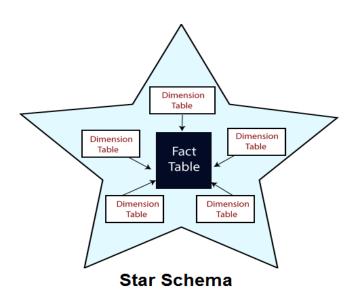
Slika 4. Prikaz dataseta, [autorski rad]



Slika 5. Prikaz atributa tablice vgsales, [autorski rad]

3.3. Model zvijezde

Zvjezdasti oblik sheme možemo definirati kao osnovni oblik dimenzijskog modela gdje se podaci organiziraju u dimenzije i činjenice.



Slika 6. Model zvijezde, [5]

Činjenica se definira kao događaj koji se broji ili mjeri poput prijave ili prodaje a dok dimenzija može uključivati referentne podatke o činjenici koji se odnose na podatke o datumima, nekim predmetima ili samim kupcima. Sama shema modela zvijezda nam predstavlja relacijsku shemu čiji dizajn predstavlja višedimenzionalni model podataka, još se opisuje i kao eksplicitna shema skladišta podataka iz razloga što se entiteti u shemi simuliraju

kao zvijezde s točkama koje se razilaze od središnje tablice. Tablice činjenice može uključivati ili činjenicu na razini detalja ili činjenice koje uključuju agregirane činjenice koje se također mogu nazivati i sažetim tablicama. Dimenzijske tablice obično se sastoje od jedne ili više hijerarhija koje kategoriziraju podatke. Primarni ključevi svake tablice dimenzija dio su složenih primarnih ključeva tablice činjenica. [5]

3.3.1. Dimenzijska tablica rankname

Dimenzijska tablica rankname sastoji se od dva atributa. Prvi atribut je naziva *idname*, a drugi atribut je naziva *nameRank*. Kod atributa *idname*, koji je ujedno i primarni ključ postavljen je na *auto increment*, a dok je atribut *nameRank* dodijeljen tip podatka VARCHAR (255). Da bi dobili rezultat tablice koji se prikazan na sljedećoj fotografiji potrebno je napisati sljedeći upit:

INSERT INTO rankname (nameRank) SELECT DISTINCT Name FROM vgsales;

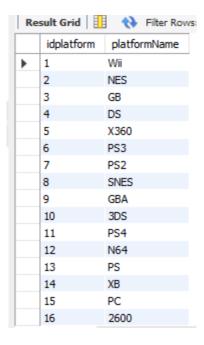


Slika 7. Dimenzijska tablica rankname, [autorski rad]

3.3.2. Dimenzijska tablica platform

Sljedeća dimanezijska tablica platform sastoji se od dva atributa, *idplatform* koji je ujedno i primarni ključ te je postavljen na *auti increment* i *platformName* koji sadrži tip podatka VARCHAR (255). Rezultat tablice prikazan je na sljedećoj fotografiji i sadrži sljedeći upit:

INSERT INTO platform(platformname) SELECT DISTINCT Platform FROM vgsales;

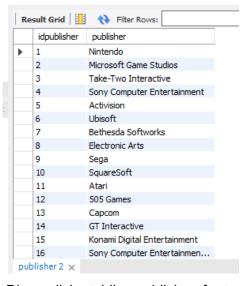


Slika 8. Dimenzijska tablica platform, [autorski rad]

3.3.3. Dimenzijska tablica publisher

U nastavku se nalazi prikaz rezultata dimenzijske tablice publisher koja se sastoji od atributa primarnog ključa naziva *idpublisher*, koji također je postavljen na *auto increment*, te drugog atributa *publisher*_koji se odnosi na samo ime izdavača videoigre i sadrži tip podatka VARCHAR (255). Upit koji je korišten za dobivanje rezultata glasi:

INSERT INTO publisher(publisher) SELECT DISTINCT Publisher FROM vgsales;



Slika 9. Dimenzijska tablica publisher, [autorski rad]

3.3.4. Dimenzijska tablica genre

Dimenzijska tablica genre sastoji se također od dva atributa, a to su atribut *idgenre* i *genreName* i on se odnosi na naziv žanra dotične videoigre. Kao i kod prethodnih primarnih ključeva, tako je i ovdje *idgenre* postavljen *auto increment, not null*, a dok je *genreName* dodijeljen tip podatka VARCHAR(255). Za prikaz rezultata tablice kao što je to prikazano sljedećoj fotografiji korišten je sljedeći upit:

INSERT INTO genre(genreName) SELECT DISTINCT Genre FROM vgsales;

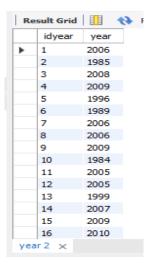


Slika 10. Dimenzijska tablica genre, [autorski rad]

3.3.5. Dimenzijska tablica year

Sljedeća dimenzijska tablica sastoji se od atributa *idyear* i *year*. Prvom atributu je dodijeljen *auto increment i not null*, a drugom atributu je dodijeljen tip podatka INT. Upit glasi:

INSERT INTO year(year) SELECT DISTINCT Year FROM vgsales;



Slika 11. Dimenzijska tablica year, [autorski rad]

3.3.6. Dimenzijska tablica sales

Sljedeća dimenzijska tablica naziva sales sastoji se od ukupno četiri atributa,a to su redom navedeni: *idsales, name, naSales i euSales.* U ovoj tablici atributu *idsales* koji je ujedno i primarni ključ ove tablice, dodijeljen *auto increment i not null*, atributu name koji se odnosi na naziv videoigre, dodijeljen je tip podatka VARCHAR (255), a dok su ostalim atributima *naSales i euSales* dodijeljeni tipovi podataka DOUBLE. Kako bi dobili rezultate tablice koji su prikazani na sljedećoj fotografiji korišten je sljedeći upit:

INSERT INTO sales(name,naSales,euSales) SELECT Name, NA_Sales,EU_Sales FROM vgsales;

	idsales	name	naSales	euSales		
•	1	Wii Sports	41.49	29.02		
	2	Super Mario Bros.	29.08	3.58		
	3	Mario Kart Wii	15.85	12.88		
	4	Wii Sports Resort	15.75	11.01		
	5	Pokemon Red/Pokemon Blue	11.27	8.89		
	6	Tetris	23.2	2.26		
	7	New Super Mario Bros.	11.38	9.23		
	8	Wii Play	14.03	9.2		
	9	New Super Mario Bros. Wii	14.59	7.06		
	10	Duck Hunt	26.93	0.63		
	11	Nintendogs	9.07	11		
	12	Mario Kart DS	9.81	7.57		
	13	Pokemon Gold/Pokemon Silver	9	6.18		
	14	Wii Fit	8.94	8.03		
	15	Wii Fit Plus	9.09	8.59		
	16	Kinect Adventures!	14.97	4.94		

Slika 12. Dimenzijska tablica sales, [autorski rad]

3.4. UPDATE nad tablicom vgsales

U nastavku su prikazani upiti koji se odnose na ažuriranje tablice vgsales:

UPDATE vgsales v INNER JOIN genre g on v.Genre = g.genreName SET v.Genre = g.idgenre;

UPDATE vgsales v INNER JOIN platform p on v.Platform = p.platformName SET v.Platform = p.idplatform;

UPDATE vgsales v INNER JOIN publisher p on v.Publisher = p.publisher

```
SET v.Publisher = p.idpublisher;

UPDATE vgsales v INNER JOIN name n on v.Name = n.idname

SET v.Name = n.nameRank;

UPDATE vgsales v INNER JOIN sales s on v.Name = s.name

SET v.Name = s.idsales;
```

3.5. ALTER tablice vgsales

U nastavku se nalaze upiti koji se odnose na prethodno izrađene tablice:

```
ALTER TABLE vgsales MODIFY Ranked int;
ALTER TABLE vgsales MODIFY Genre int;
ALTER TABLE vgsales MODIFY Platform int;
ALTER TABLE vgsales MODIFY Publisher int;
ALTER TABLE vgsales MODIFY Name int;
```

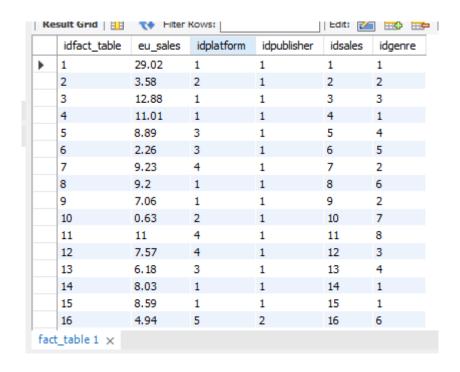
3.6. Činjenična tablica fact_table

U ovom primjeru prikazat ćemo činjeničnu tablicu koja se sastoji od ukupno šest atributa, a to su:

- idfact_table
- eu_sales
- > idplatform
- > idpublisher
- > idsales
- > idgenre

Atribut koji su označeni sa id prefiksom, predstavljaju vanjske ključeve odgovarajuće dimenzijske tablice koje su povezane sa prethodnim činjeničnim tablicama. Kako bi se dohvatile sve potrebne vrijednosti koristi se sljedeći upit:

```
INSERT INTO fact_table(eu_sales, idplatform, idpublisher, idsales, idgenre) SELECT EU_Sales, Platform, Publisher, Name, Genre FROM dposavec.vgsales;
```

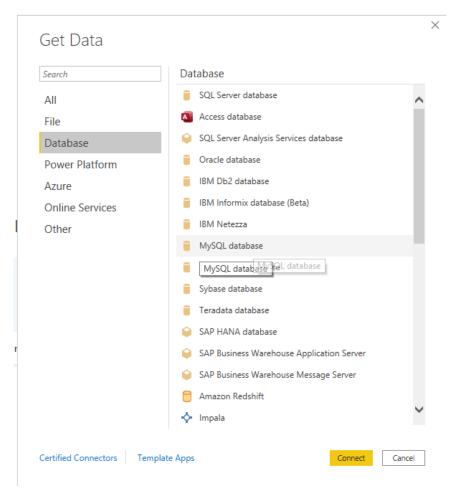


Slika 13. Prikaz činjenične tablice fact_table, [autorski rad]

4. Analiza uz pomoć Power BI alata

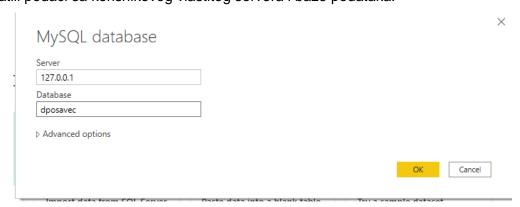
Alat Power BI paket je alat za poslovnu analitiku koji pružaju uvidu u sva područja koja se odnose na organizacije nekog područja. Sadrži i mogućnost stvaranja personaliziranih nadzornih ploča s jedinstvenim pogledom na tvrtku, isto tako možemo koristiti i relevantne podatke. Bez obzira da li se korisnikovi podaci nalaze u excel proračunskim tablicama, lokalni izvori podataka, streaming podaci ili usluge u oblaku, alat Power BI omogućuje korisniku integraciju podataka s različitih izvora. [6]

Prilikom otvaranja desktop verzije alata Power BI, potrebno je dohvatiti podatke koje želimo iskoristiti u radu s izvještajima. Na sljedećoj fotografiji nalazi se putanja koju je potrebno izvršiti i spojiti na izvor s kojega želimo dohvatiti podatke koje se nalazi na adresi 127.0.0.1 i port 3306. Radi se o MySQL-u a baza podataka je naziva dposavec.

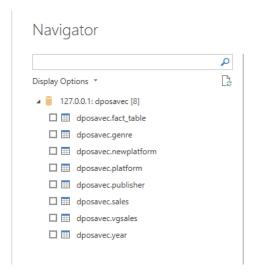


Slika 14. Postupak dodavanja podataka u PowerBI, [autorski rad]

Na sljedećoj fotografiji nalazi se mjesto na kojemu je potrebno popuniti polja kako bi se dohvatili podaci sa korisnikovog vlastitog servera i baze podataka.

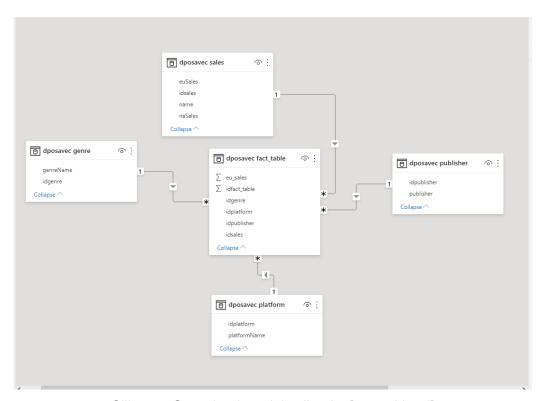


Slika 15. Popunjavanje korisnikovih podataka, [autorski rad]



Slika 16. Prikaz tablica u PowerBI, [autorski rad]

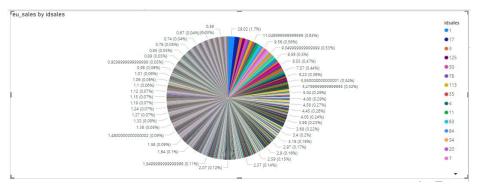
Nakon prethodnog koraka dobivamo dijaloški okvir koji je prikazan kao na prethodnoj fotografiji i tada možemo odabrati sve tablice sa kojima želimo izrađivati izvještaje. Na sljedećoj fotografiji nalazi se dobiveni generirani model zvijezda kojega dobijemo nakon odabira u navigatoru svih tablica.



Slika 17. Generirani model zvijezde, [autorski rad]

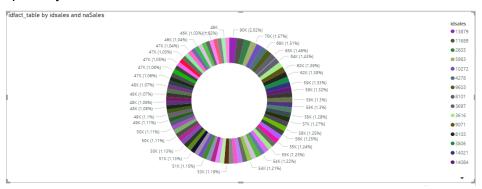
4.1. Generirani izvještaji

Pomoću alata Power BI u nastavku će biti prikazani primjeri izvještaja. Na sljedećoj fotografiji nalazi se prikaz prodaje videoigara na području Europe.

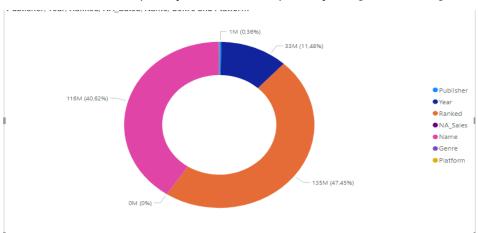


Slika 18. Prikaz prodaje videoigara u Europi, [autorski rad]

Na sljedećoj fotografiji nalazi se izvještaj prodaje koji se odnose na prodaju u određenim područjima.



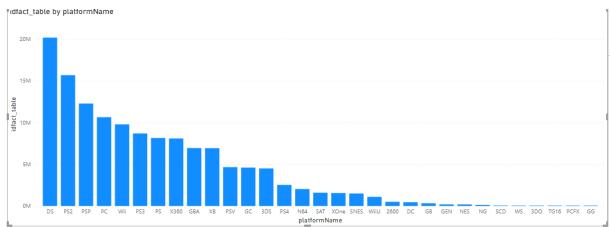
Slika 19. Prikaz prodaje u određenim područjima, [autorski rad]



Slika 20. Prikaz zastupljenosti atributa u bazi podataka, [autorski rad]

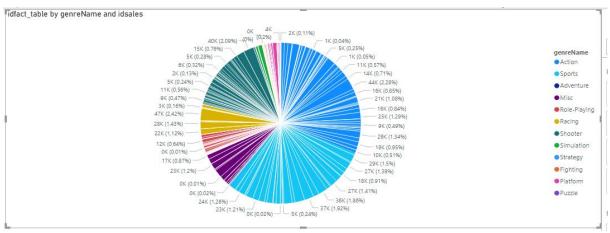
Prethodna fotografija prikazuje zastupljenost svakog atributa u koji se odnosi na izdavače, naziv videoigre, žanr i ostalo.

Sljedeća fotografija zastupljenost određene videoigre po njezinoj platformi, pa tako možemo vidjeti tri najzastupljenije platforme koje su u vodstvu, a to su: DS, PS2 i PSP.



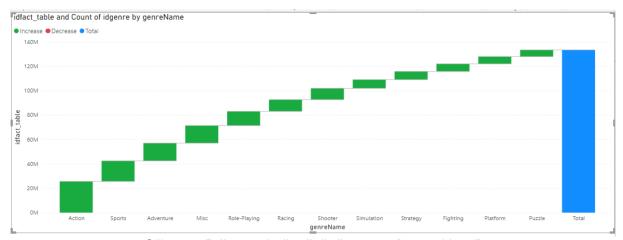
Slika 21. Prikaz najzastupljenijih platformi, [autorski rad]

Pomoću sljedeće fotografije možemo vidjeti rezultate prodaje videoigara prema žanru na koje se odnose, a to mogu biti akcijske videoigre, avanturističke, sportske, zabavne i slično.

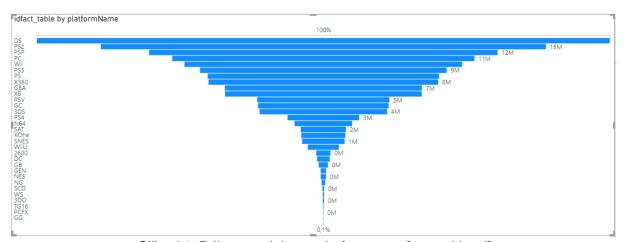


Slika 22. Prikaz prodaje po žanru, [autorski rad]

Sljedeća fotografija prikazuje zbroj pojedinačnih žanrova po njihovim i rasponu prodaje u dotičnim kategorijama.



Slika 23. Prikaz pojedinačnih žanrova, [autorski rad]



Slika 24. Prikaz prodaje po platformama, [autorski rad]

Prethodna fotografija prikazuje zastupljenost prodaje videoigara po platformama.

5. Zaključak

Ovaj projekt izrađen je s ciljem upoznavanja novih tehnologija, poput Power BI alat kao i ponavljanje znanja prethodnih godina koje se odnose na baze podataka. Samim time, uz pomoć novih tehnologija i daljnjim istraživanjima uspješno je riješena analiza statistike prodaje videoigara koja je ujedno i glavna tema ovog seminarskog rada. Pomoći određenih upita dobili smo uvid u rješenja potrebnih dimenzijskih tablica, činjenične tablice, te u konačnici i vizualizirani izvještaj uz pomoć kojega smo na kraju jasno predočili rješenja. Uz prethodno spomenute alate koji su bili korišteni u ovome radu Power BI i MySQL Workbench, koristio se i besplatan dataset koji je bio preuzet s web stranice Kaggle.com. Uz velikog broj zapisa i bazi podataka sama rješenja u konačnici su bila vrlo kvalitetna zahvaljujući vrlo kvalitetnim i preciznim podacima u tablici. Na samome kraju možemo reći kako se skladišta podataka u današnje vrijeme tehnologije vrlo brzo razvijaju u smislu širenja podataka, zahtjevnosti što većeg kapaciteta za skladištenje podataka. Za upravljanje skladištem podataka i rad s njihovim podacima, potrebni su stručnjaci koji su specijalizirani za rad u takvom području podataka jer s rastom tehnologije dolazi i njihovog proboja, odnosno napada zlonamjernih osoba s ciljem otuđivanja podataka. Isto tako možemo reći kako nam skladište podataka predstavlja i jedinstvenu sliku poslovne realnosti kao i definiranje cjelokupne poslovne strategije. Samo skladište podataka nam predstavlja informacijsku tehnologiju koja se sa svojim aspektima i činjenicama opisuje kao kooperativan i timski rad koji se usko vezan uz stručnjake na informatičkom ali i u bilo kojem području, u globalu ono nam predstavlja poslovni i tehnički informacijski svijet.

Popis literature

- [1] K.Ćurko (2001.): *Skladište podataka sustav za potporu odlučivanju*, dostupno na: https://hrcak.srce.hr/file/45126, pristupano 25.5.2021.
- [2] Ottomatik.io (2021.): *Guide To MySQL Workbench Understand How It Works*, dostupno na: https://ottomatik.io/blog/mysql-workbench/, pristupano 25.5.2021.
- [3] Docs.microsoft.com (2021.): What is Power BI?, dostupno na: https://docs.microsoft.com/en-us/power-bi/fundamentals/power-bi-overview, pristupano: 25.5.2021.
- [4] Guru99.com (2021.): ETL (Extract, Transform, and Load) Process in Dana Warehouse, dostupno na: https://www.guru99.com/etl-extract-load-process.html, pristupano 25.5.2021.
- [5] Javatpoint.com (2021.): What is Star Schema?, dostupno na: https://www.javatpoint.com/data-warehouse-what-is-star-schema, pristupano 25.5.2021.
- [6] Ambit-group.com (2021.): *Microsoft Power Platform*, dostupno na: https://ambit-group.com/en/products-solutions/microsoft-power-platform, pristupano 25.5.2021.

Popis slika

Slika 1. Prikaz dijela preuzetog skupa podataka, [autorski rad]	4
Slika 2. Prikaz servera, [autorski rad]	5
Slika 3. Popis tablica, [autorski rad]	6
Slika 4. Prikaz dataseta, [autorski rad]	6
Slika 5. Prikaz atributa tablice vgsales, [autorski rad]	7
Slika 6. Model zvijezde, [5]	7
Slika 7. Dimenzijska tablica rankname, [autorski rad]	8
Slika 8. Dimenzijska tablica platform, [autorski rad]	9
Slika 9. Dimenzijska tablica publisher, [autorski rad]	9
Slika 10. Dimenzijska tablica genre, [autorski rad]	10
Slika 11. Dimenzijska tablica year, [autorski rad]	10
Slika 12. Dimenzijska tablica sales, [autorski rad]	11
Slika 13. Prikaz činjenične tablice fact_table, [autorski rad]	13
Slika 14. Postupak dodavanja podataka u PowerBI, [autorski rad]	14
Slika 15. Popunjavanje korisnikovih podataka, [autorski rad]	
Slika 16. Prikaz tablica u PowerBI, [autorski rad]	15
Slika 17. Generirani model zvijezde, [autorski rad]	15
Slika 18. Prikaz prodaje videoigara u Europi, [autorski rad]	16
Slika 19. Prikaz prodaje u određenim područjima, [autorski rad]	16
Slika 20. Prikaz zastupljenosti atributa u bazi podataka, [autorski rad]	
Slika 21. Prikaz najzastupljenijih platformi, [autorski rad]	17
Slika 22. Prikaz prodaje po žanru, [autorski rad]	17
Slika 23. Prikaz pojedinačnih žanrova, [autorski rad]	18
Slika 24. Prikaz prodaje po platformama, [autorski rad]	18